Al-Driven
Temperature
Control System

Data Scientist: George Glor





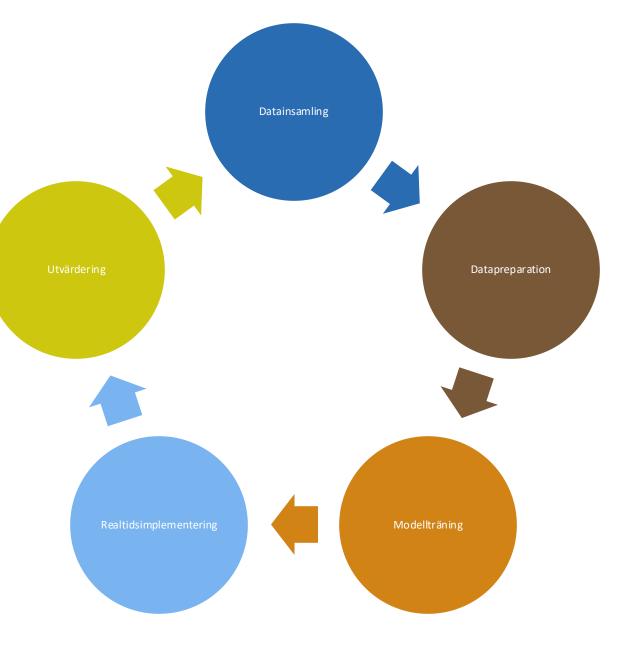
Introduktion

Förr i tiden var temperaturreglering inte så effektiv. Människor märkte ofta att det blivit kallt för sent och höjde värmen mycket mer än nödvändigt. Detta ledde till att man använde mer energi och slösade mer pengar. Manuell justering av temperaturen var helt enkelt inte tillräckligt snabb eller exakt för att hålla en jämn och behaglig inomhustemperatur.

Med den här bakgrunden skapade jag ett smart system som använder AI och IOT för att lösa problemet. Systemet förutser inomhustemperaturen och gör små justeringar i uppvärmningen eller kylningen automatiskt, vilket sparar både energi och pengar. Målet är att hålla en stabil temperatur runt 20°C, vilket ger en bekväm och hållbar lösning.

Steg för det Al-drivna temperaturkontrollsystemet

- Datainsamling
- Historiska väderdata och realtidsuppdateringar samlades in.
- Datan innehöll temperatur, luftfuktighet, vindhastighet och lufttryck.
- Datapreparation
- Datarengöring (hantering av saknade värden, omvandling av enheter, etc.).
- Feature engineering skapade nya variabler som "Temperaturintervall" och "Luftfuktighet-Vind Interaktion."
- Modellträning
- Maskininlärningsmodeller: Linjär regression, Lasso och Ridge användes.
- Modellernas prestanda utvärderades med hjälp av RMSE för att hitta den bästa modellen.
- Realtidsimplementering
- OpenWeatherMap API integrerades för att hämta levande väderdata.
- Förutsägelser användes för att dynamiskt justera uppvärmning eller kylning.
- Utvärdering
- Systemet testades i realtid.
- Modellerna presterade bra och höll inomhustemperaturen stabil runt 20°C.



Training the Models

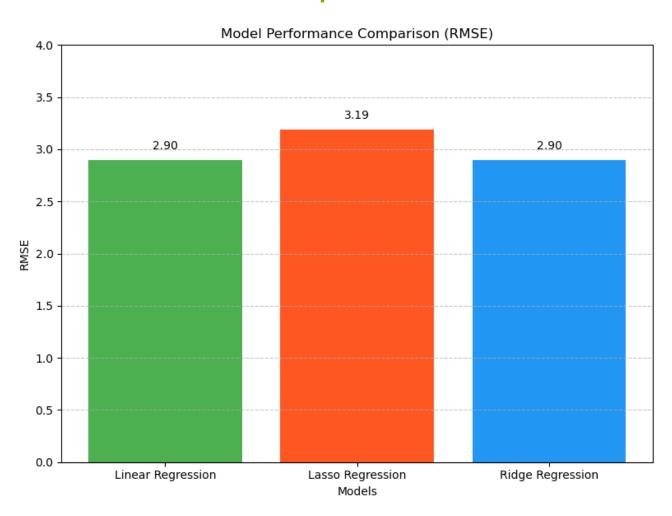
- from skleam.linear_model import LinearRegression, Lasso, Ridge
- from sklearn.metrics import mean_squared_error
- models = {
- "Linear Regression": LinearRegression(),
- "Lasso Regression": Lasso(alpha=0.1),
- "Ridge Regression": Ridge(alpha=1.0)
- •
- for name, model in models.items():
- model.fit(X_train, y_train)
- predictions = model.predict(X_test)
- rmse = mean_squared_error(y_test, predictions, squared=False)
- print(f"{name} RMSE: {rmse:.2f}")

Jämförelse av Modellernas Prestanda

- Linjär Regression presterade bäst med en RMSE på 2.90 och en noggrannhet på 96.5%, vilket visar att modellen effektivt kan förutsäga inomhustemperaturer.
- Ridge Regression presterade nästan lika bra med en RMSE på 2.90 och en något lägre noggrannhet på 96.2%, vilket visar att modellen är robust och klarar små dataset utan överanpassning.
- Lasso Regression hade högst RMSE på 3.19 och den lägsta noggrannheten på 94.8%, troligtvis på grund av att den reducerar vissa parametrars påverkan.
- Beräkningstid: Alla modeller var effektiva. Linjär regression var snabbast med en beräkningstid på o.o2 sekunder, vilket gör den idealisk för realtidsjusteringar.

Model	RMSE	Accuracy (%)	Time (s)
Linear Regression	2.90	96,5	0.02
Class 2Lasso Regression	73.19	94.8	0.15
Ridge Regression	2.90	96.2	0.12

Model Performance Comparison



Framtida Förbättringar

- Insamling av fler data för att förbättra modellernas noggrannhet.
- Implementering av mer avancerade algoritmer som neurala nätverk.
- Integration med smarta termostater och IoT-enheter för ökad effektivitet.

Resultat

```
--- Temperature Adjustment ---
Outdoor Temperature: 0.85°C
Predicted Indoor Temperature: 7.6283333333333334°C
Current indoor temperature: 18.0°C
Temperature is low. Turning ON heating.
Updated Indoor Temperature: 19.0°C
--- End of Update ---
--- Temperature Adjustment ---
Outdoor Temperature: 0.9°C
Predicted Indoor Temperature: 7.6283333333333334°C
Current indoor temperature: 19.0°C
Temperature is low. Turning ON heating.
Updated Indoor Temperature: 20.0°C
--- End of Update ---
--- Temperature Adjustment ---
Outdoor Temperature: 2.6°C
Predicted Indoor Temperature: 7.6283333333333334°C
Current indoor temperature: 20.0°C
Temperature is stable. No action required.
Updated Indoor Temperature: 20.0°C
--- End of Update ---
```

Tack så mycket